

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
САНКТ-ПЕТЕРБУРГСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ ПЕТРА ВЕЛИКОГО
Институт электроники и телекоммуникаций
Высшая школа прикладной физики и космических технологий

Работа допущена к защите
И.о. директора ВШПФиКТ

_____ А.Л. Гельгор
«_____» _____ 2022 г.

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
БАКАЛАВРА**

**ПОВЫШЕНИЕ КАЧЕСТВА РЛИ ЗА СЧЁТ ПРИМЕНЕНИЯ
НЕЙРОННЫХ СЕТЕЙ ДЛЯ ФИЛЬТРАЦИИ
МУЛЬТИПЛИКАТИВНОГО ШУМА**

по направлению подготовки 11.03.02 – «Инфокоммуникационные технологии
и системы связи»

Направленность (профиль) 11.03.02_06 «Оптические телекоммуникационные
системы»

Выполнил студент группы 4931102/80602

А.В. Корчагина

Руководитель ассистент ВШПФиКТ, к.т.н.

В.А. Павлов

Руководитель профессор ВШПФиКТ, д.т.н.

С.Б. Макаров

Консультант по нормоконтролю, ассистент

Е.А. Савченко

Санкт-Петербург
2022

УТВЕРЖДАЮ

Директор высшей школы
прикладной физики и космических
технологий

_____ / А.Л. Гельгор

« » _____ 2022 г.

ЗАДАНИЕ

по выполнению выпускной квалификационной работы

студенту _____ Корчагиной Алёне Витальевне _____ гр. 4931102/80602

фамилия, имя, отчество (при наличии), номер группы

1. Тема работы: «Повышение качества РЛИ за счёт применения нейронных сетей для фильтрации мультипликативного шума»

2. Срок сдачи студентом законченной работы: 01 июня 2022

3. Исходные данные по работе: _____

1) Верба В. С., Неронский Л. Б., Осипов И. Г. и др. Радиолокационные системы землеобзора космического базирования. / Под редакцией доктора технических наук, профессора В. С. Вербы. М.: Радиотехника, 2010. 680 с.

2) Кондратенков Г.С., Фролов А.Ю. Радиовидение. Радиолокационные системы дистанционного зондирования Земли. Учебное пособие для вузов / Под редакцией Г. С. Кондратенкова. – М.: Радиотехника. 2005. – 368 с.

3) <http://arxiv.org/>

4) <http://ieeexplore.org/Xplore/home.jsp>

5) <https://www.sciencedirect.com/>

Оптические изображения

4. Содержание работы (перечень подлежащих разработке вопросов):

1) Обзор современных нейросетевых подходов для фильтрации мультипликативного шума на изображениях

2) Разработка и обучение нейронной сети для фильтрации мультипликативного шума.

3) Выбор оптимального параметра фильтра.

4) Исследование влияния фильтра на объекты различных форм.

5) Сравнение нейросетевого подхода с классическими методами фильтрации мультипликативного шума.

5. Перечень графического материала (с указанием обязательных чертежей): _____

1) Схема архитектуры нейронной сети для фильтрации мультипликативного шума.

2) График зависимости метрик оценки качества от параметра фильтра.

3) Пример отфильтрованных изображений.

6. Консультанты по работе (если есть): Нет

7. Дата выдачи задания 10 мая 2022 г.

Руководитель ВКР

(подпись)

В.А. Павлов

инициалы, фамилия

Руководитель ВКР

(подпись)

С.Б. Макаров

инициалы, фамилия

Задание принял к исполнению

«10» мая 2022 г.

(дата)

Студент

(подпись)

А.В. Корчагина

инициалы, фамилия

РЕФЕРАТ

На 39 с., 14 рис., 4 табл., 17 источн.

КЛЮЧЕВЫЕ СЛОВА: РАДИОЛОКАЦИОННОЕ ИЗОБРАЖЕНИЕ, РАДИОЛОКАЦИОННОЕ СИНТЕНЗИРОВАНИЕ АПЕРТУРЫ, МУЛЬТИПЛИКАТИВНЫЙ ШУМ, ФИЛЬТРАЦИЯ СПЕКЛ-ШУМА, ПАРАМЕТРЫ ФИЛЬТРОВ, НЕЙРОННЫЕ СЕТИ, ОПТИЧЕСКОЕ ИЗОБРАЖЕНИЕ

Тема выпускной квалификационной работы: «Повышение качества РЛИ за счёт применения нейронных сетей для фильтрации мультипликативного шума».

Объект исследования – фильтрация мультипликативного шума

Цель работы – реализация и применение алгоритма фильтрации мультипликативного спекл-шума для повышения качества радиолокационных изображений (РЛИ), полученных с помощью радиолокатора с синтезированной апертурой (РСА), на основе искусственных нейронных сетей (ИНС).

Для фильтрации спекл-шума была разработана архитектура нейронной сети, обучение которой производилось на разработанном наборе данных. Для повышения качества РЛИ провели поиск оптимального параметра разработанного фильтра мультипликативного спекл-шума. На изображениях с различными особенностями протестировали и сравнили работу разработанного фильтра со стандартными фильтрами спекл-шума.

Результатом работы является обученная нейронная сеть, способная более эффективно удалять мультипликативный спекл-шум на РЛИ, чем стандартные фильтры. Применение разработанного фильтра позволит проводить обработку (детектирование объектов, сегментация областей и др.) радиолокационных изображений без влияния спекл-шума.

ABSTRACT

39 pages, 14 pictures, 4 tables

KEYWORDS: Radar image, synthetic-aperture radar, multiplicative noise, speckle noise filtering, filter parameters, neural networks, optical images.

The subject of the graduate qualification work is “Improving the quality of radar images by using neural networks to filter multiplicative noise”.

The given work is devoted to the implementation and application of algorithm for filtering of multiplicative speckle noise based on artificial neural networks to improve the quality of radar images obtained using a synthetic aperture radar (SAR). A neural network architecture was developed to filter of multiplicative speckle noise, which was trained on the developed data set. A search was made for the optimal parameter of the developed filter of multiplicative speckle noise to improve the quality of radar images. We tested and compared the operation of the developed filter with standard speckle noise filters on images with different characteristics.

The result of the work is a trained neural network that can more effectively remove multiplicative speckle noise on radar images than standard filters. The use of the developed filter will allow the processing (object detection, area segmentation, etc.) of radar images without the influence of speckle noise.

СОДЕРЖАНИЕ

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ.....	7
ВВЕДЕНИЕ.....	8
1 Радиолокационное синтезирование апертуры и фильтрация мультипликативного спекл-шума.....	10
1.1 Принцип действия радиолокатора с синтезированной апертурой.....	10
1.2 Алгоритм формирования РЛИ.....	12
1.3 Спекл-шум и методы его фильтрации.....	14
1.4 Выводы.....	15
2 Нейросетевой подход фильтрации мультипликативного шума.....	17
2.1 Архитектура ИНС для фильтрации мультипликативного шума.....	17
2.2 Оценка качества фильтрации мультипликативного шума.....	18
2.3 Выводы.....	21
3 Фильтрация мультипликативного шума на РЛИ.....	22
3.1 Разработка фильтра мультипликативного шума.....	22
3.2 Применение фильтра мультипликативного шума на реальных изображениях.....	26
3.3 Выводы.....	34
ЗАКЛЮЧЕНИЕ.....	36
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	38

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

БПФ – быстрое преобразование Фурье

ДЗЗ – дистанционное зондирование земли

ДНА – диаграмма направленности антенны

ИНС – искусственная нейронная сеть

ЛА – летательный аппарат

ЛЧМ – линейная частотная модуляция

ОБПФ – обратное быстрое преобразование Фурье

РБО – радиолокатор бокового обзора

РЛИ – радиолокационное изображение

РЛС – радиолокационная станция

РСА – радиолокационное синтезирование апертуры

СА – синтезирование апертуры

НС – нейронная сеть

MAE – mean absolute error (средний модуль отклонения)

MAP – maximum a posterior probability (оценка апостериорного максимума)

MSE – mean square error (средний квадрат отклонения)

PSNR – peak signal-to-noise ratio (пиковое отношение сигнал/шум)

SSIM – structural similarity index (индекс структурного сходства)

ВВЕДЕНИЕ

Радиолокационное изображение (РЛИ) – это изображение, полученное путём дистанционного зондирования земли (ДЗЗ) с помощью радиолокационного устройства.

Радиолокационные изображения с высоким разрешением обычно получают с помощью радиолокатора с синтезированной апертурой (РСА), который размещается на борту авиационных и космических носителей. РСА, обладая высокой разрешающей способностью по путевой и наклонной дальностям, позволяют получить изображения земной поверхности и находящихся на ней объектов, не испытывая трудностей при неблагоприятных метеорологических условиях и недостаточной освещённости.

Применение РСА позволяет решать различные задачи общего и специального назначения: обнаружение малоразмерных объектов, мониторинг состояния объектов промышленной и транспортной инфраструктуры, управления устранением последствий чрезвычайных ситуаций, картографирование местности, подводных рельефов, поверхностей планет, ведение геологической разведки и многое другое [1, 2, 3].

Радиолокационные изображения обладают особенностью в виде мультипликативного спекл-шума, который вызывает зернистость фона. Такой вид шума обусловлен когерентным сложением сигналов, принятых от большого количества элементарных отражателей, находящихся в пределах одного элемента разрешения подстилающей поверхности [2].

Наличие спекл-шума приводит к снижению качества РЛИ, препятствуя извлечению полезной информации из них. Следовательно, для повышения качества РЛИ и минимизации ошибок обнаружения объектов на РЛИ необходимо осуществить фильтрацию спекл-шума.

Существует множество алгоритмов снижения мультипликативного спекл-шума, но ни один из них не справляется с задачей полностью, поэтому имеет смысл исследования и разработки нового алгоритма, способного

справляться с этой задачей более эффективно. На сегодняшний день в задачах обработки изображений активно используются различные архитектуры нейронных сетей (НС). В связи с этим предлагается рассмотреть возможность применения метода фильтрации мультипликативного спекл-шума на основе НС.

Целью работы является реализация и применение алгоритма фильтрации мультипликативного спекл-шума на основе нейронных сетей для повышения качества РЛИ.


Задачами, необходимыми для достижения поставленной цели, являются:

1. Разработка архитектуры нейронной сети для фильтрации мультипликативного шума;
2. Выбор оценки качества изображений после обработки мультипликативного шума;
3. Обучение нейронной сети на разработанном наборе данных и оценка полученных результатов;
4. Применение и сравнение метода фильтрации нейросетевым подходом с классическими фильтрами на реальных изображениях.

1 Радиолокационное синтезирование апертуры и фильтрация мультипликативного спекл-шума

1.1 Принцип действия радиолокатора с синтезированной апертурой

Радиолокационные системы являются средством активного наблюдения, использующим облучение земной поверхности зондирующим сигналом посредством движения летательного аппарата (ЛА), прием и обработку отраженных сигналов и формирование выходных РЛИ, содержащих информацию о разных свойствах объекта наблюдения. При радиолокационном обзоре основным режимом работы системы является боковой обзор, при котором антенна неподвижна относительно корпуса ЛА [1, 2]. Схема полета ЛА с радиолокатором бокового обзора (РБО) представлена на Рисунке 1.1.



x – проекция траектории полета на подстилающую поверхность (путевая дальность), y – дальность до отражающего элемента на подстилающей поверхности (горизонтальная дальность), γ_i – угол падения, отсчитываемый от местной вертикали, R – наклонная дальность, H – высота полета.

Рисунок 1.1 – Схема полета ЛА с РБО

Детальность РЛИ зависит от линейной разрешающей способности радиолокатора, характеризующая его способность различать две близко расположенные друг к другу точечные цели по дальности и азимуту. Детальность РЛИ тем выше, чем меньше разрешающая способность РБО по наклонной дальности ρ_R и вдоль линии пути (по азимуту) ρ_X , то есть чем меньше площадь элемента разрешения.

Разрешающая способность РБО по наклонной дальности ρ_R , а также разрешение поперек линии пути (горизонтальная дальность на местности) ρ_Y определяются шириной спектра зондирующего сигнала [2]:

$$\rho_Y = \frac{\rho_R}{\sin \gamma_i} = \frac{c}{2\Delta F} \frac{1}{\sin \gamma_i}, \quad (1.1)$$

где ΔF – ширина спектра зондирующего импульса.

Для уменьшения ρ_R используют сложные зондирующие сигналы, в качестве которых чаще всего применяются линейно-частотные модулированные (ЛЧМ) импульсы, обладающие подходящим свойством обеспечения необходимой ширины полосы частот с большой длительностью импульса.

Разрешающая способность РБО вдоль линии пути ρ_X определяется шириной диаграммы направленности антенны (ДНА) θ_X и расстоянием до цели R [2]:

$$\rho_X = \theta_X R = R \frac{\lambda}{D}, \quad (1.2)$$

где λ – длина волны РБО,

D – горизонтальный размер антенны.

Для уменьшения ρ_X требуется использование узких ДНА. Учитывая, что ширина ДНА обратно пропорциональна длине антенны, то размещение антенн больших размеров на ЛА не представляет возможным. Данный недостаток решается применением в РБО метода синтеза апертуры антенны [1].

Принцип действия радиолокатора с синтезированной апертурой (РСА) основан на перемещении реальной апертуры антенны, находящейся на борту ЛА, для последовательного формирования антенной решетки при полете ЛА по определённой (обычно прямолинейной) траектории. Антенна, которая находится на носителе радиолокационной станции (РЛС), движущегося вдоль траектории и излучая зондирующие импульсы, принимает отраженные от точечной цели на поверхности земли сигналы. Причем два сигнала, принятые от одной цели при соседних положениях носителя РЛС с антенной, проходят разные расстояния и с учетом прохода в двух направлениях (к цели и от неё) отличаются по фазе на [1, 2]:

$$\Delta\varphi = \omega t_{\Delta R} = 2\pi f_0(2\Delta R/c) = 4\pi\Delta R/\lambda, \quad (1.3)$$

где ΔR – разность хода.

1.2 Алгоритм формирования РЛИ

Алгоритм согласованной обработки с целью формирования РЛИ можно разделить на два независимых этапа: внутрипериодную обработку каждого принятого импульса и межпериодную обработку траекторного сигнала, т.е. пачки импульсов, принятых от одного элементарного отражателя на длине синтезируемой апертуры. Согласованная обработка является линейной операцией, поэтому порядок следования этих этапов может выполняться произвольно, а в некоторых случаях даже одновременно.

Основными задачами внутрипериодной обработки являются фильтрация принятого сигнала от шумов и получение заданного разрешения по дальности, а для межпериодной обработки – получение РЛИ с заданным разрешением по азимуту.

Процесс синтезирования апертуры антенны (получение сигнала P_i , характеризующего РЛИ элемента разрешения) сводится к реализации алгоритма [3]:

$$P_i = \left| \int_{-T_c/2}^{T_c/2} U_i(t) h_i(t) dt \right|, \quad (1.4)$$

где T_c – время синтезирования,

$U_i(t)$ – траекторный сигнал от i -ой точечной цели,

$h_i(t)$ – опорная функция системы обработки для i -ой цели.

В качестве опорной функции, на согласование которой основывается обработка сигналов РСА, выбирается функция, комплексно- сопряженная с сигналом, отраженным от одиночной точечной цели [3]:

$$h_i(t) = W(t) \exp \left\{ j \frac{4\pi}{\lambda} r_{ni}(t) \right\}, \quad (1.5)$$

где $W(t)$ — действительная весовая функция синтезированной апертуры,

r_{ni} – расстояние от носителя РЛС до i -ой точечной цели.

Целью умножения сигнала на опорную функцию является устранение набега фазы $\Delta\varphi$. Далее происходит накопление результата умножения в течение времени T_c (операция интегрирования в формуле (1.5)) и взятие модуля. Учитывая, что траекторный сигнал РСА является импульсным, значение опорной функции $h_i(t)$ определяется в дискретные моменты времени $t = nT_n$, где n – номер зондирующего импульса, T_n – период повторения импульсов, а операция интегрирования представляет собой сумму (свёртку) произведений импульсов, принимаемых в течение времени T_c , и опорной функции [3].

Используя такой алгоритм синтезирования апертуры для обработки $N = T_c/T_n$ импульсов, необходимо проделать суммарное число операций равное [2]:

$$N_{\text{операций}} = N_\tau (N_r - N_\tau + 1) N^2, \quad (1.6)$$

где $N_\tau = \tau/T_\partial$ – число отчетов в длительности импульса,

τ – длительность зондирующего импульса,

T_0 – период дискретизации принятых сигналов,

N_r – число отчетов в строке дальности.

Сократить количество вычислительных операций можно с помощью быстрой свертки. Для этого, используя быстрое преобразование Фурье (БПФ), переводим данные из временной области в частотную, затем перемножаем спектры сигнала и опорной функции и производим обратный перевод во временную область с помощью обратного БПФ (ОБПФ). В результате таких преобразований имеется комплексное РЛИ, из которого путем взятия модуля получается амплитудное РЛИ [2, 3].

1.3 Спекл-шум и методы его фильтрации

Важной особенностью РЛИ является повышенная зернистость (неравномерность) фона, вызванная спекл-шумом. Данный шум обусловлен когерентным сложением сигналов, принятых от множества элементарных отражателей, находящихся в пределах одного элемента разрешения подстилающей поверхности.

Спекл-шум на РЛИ математически может быть описан как модель мультипликативного шума, представляющая собой умножение исходного изображения на случайный сигнал [2]. Тогда зашумленное изображение $I'(x,y)$ описывается формулой:

$$I'(x,y) = I(x,y)(1 + n(x,y)), \quad (1.7)$$

где $I(x,y)$ – исходное изображение (неискаженное),

$n(x,y)$ – случайный процесс, описывающий спекл-шум.

Поскольку наличие спекл-шума приводит к ухудшению дешифрируемости РЛИ, необходимо осуществить его фильтрацию. На практике чаще всего используются локальные фильтры, основанные на формировании локальных статистик относительно центрального пикселя в

«скользящем» окне при обработке изображения. Размер такого «скользящего окна» намного меньше, чем размер всего изображения.

К таким фильтрам относятся:

- медианный фильтр, варьируемый параметр которого является размер окна обработки [4];
- фильтр Ли, варьируемый параметр которого является размер окна обработки [5];
- фильтр Фроста, варьируемыми параметрами которого являются размер окна обработки и коэффициент демпфированный D , позволяющий регулировать гладкость фильтра [6];
- фильтр Куана, варьируемыми параметрами которого являются размер окна обработки и коэффициент A , позволяющий регулировать гладкость фильтра [7];
- Билатериальный фильтр с Гауссовым ядром, варьируемыми параметрами которого являются размер окна обработки и параметры сглаживания σ_d^2 и σ_r^2 [8];
- метод оценки с помощью апостериорного максимума (MAP), варьируемый параметр которого является размер окна обработки [9];

Также, кроме вышеперечисленных методов фильтрации, применяется фильтр анизотропной диффузии Пирсона и Малика [10], особенность которого состоит в том, что при сглаживании шума он сохраняет значимые границы и усиливает их интенсивность на изображении. Его варьируемыми параметрами являются шаг по времени Δt , параметр k и количество итераций t .

1.4 Выводы

Существует большое количество фильтров спекл-шума, имеющие в своей структуре параметры, значения которых необходимо подбирать для наилучшей их работы, что очень трудозатратно. При этом ни один из них не справляется с задачей фильтрации полностью. В связи с этим предлагается рассмотреть возможность применения метода фильтрации

мультипликативного спекл-шума на основе машинного обучения, базирующего на использовании ИНС.

Целью работы является реализация и применение алгоритма фильтрации мультипликативного спекл-шума с помощью нейронных сетей для повышения качества РЛИ.

Дальнейшими задачами, которые необходимы для достижения поставленной цели, являются:

1. Разработка метода фильтрации мультипликативного шума нейросетевым подходом;
2. Выбор оценки качества изображений после обработки мультипликативного шума нейросетевым подходом;
3. Обучение выбранного алгоритма на разработанном наборе данных и оценка полученных результатов;
4. Сравнение метода фильтрации нейросетевым подходом с классическими фильтрами на изображениях с различными особенностями.

2 Нейросетевой подход фильтрации мультипликативного шума

Одним из способов повышения качества обработки радиолокационных изображений является использование искусственных нейронных сетей (ИНС).

Искусственная нейронная сеть — это математическая модель, реализованная в программном или аппаратном обеспечении и основанная на принципах функционирования естественных для природы нейронных сетей, которые в высших живых организмах представляют собой сети нервных клеток (нейронов). Как и в природном аналоге, в ИНС основным элементом выступают нейроны, соединенные между собой синаптическими связями и образующие слои, число которых может быть разным в зависимости от сложности нейросети и ее назначения. Одним из основных преимуществ нейронной сети перед классическими алгоритмами является ее способность к обучению, основанная на изменении весов связи между нейронами во время обучения. В случае успешного обучения нейронная сеть сможет вернуть правильный результат даже при использовании входных данных, отсутствовавших в обучающей выборке [11].

2.1 Архитектура ИНС для фильтрации мультипликативного шума

В данной работе предлагается разработать фильтр мультипликативного спекл-шума, размер которого намного меньше исходного изображения, способный адаптироваться под каждый пиксель одноканального изображения и его окружения внутри «скользящего» окна размера $m \times m$, где m — нечетное число.

Для разработки такого фильтра выберем НС прямого распространения сигнала, состоящую из входного, выходного и расположенных между ними пяти скрытых слоев нейронов. Архитектура нейронной сети такого фильтра представлена на Рисунке 2.1.




Рисунок 2.1 – Архитектура НС для фильтрации мультипликативного шума

Для «скользящего» окна размера $t \times t$ входной слой НС содержит t^2 нейронов, а выходной слой – всегда один нейрон. Количество нейронов в скрытых слоях следует подбирать эмпирическим способом, исходя из результатов эксперимента.

Для обучения НС необходим полный набор входных данных с заранее известным правильным выходным значениям. На входной слой НС будем подавать сигнал в виде вектора значения яркости центрального пикселя изображения с наложенным на него спекл-шумом и его окружения внутри «скользящего» окна. Нейронная сеть, учитывая входные сигналы, вычислит ожидаемое значение яркости центрального пикселя без наложенного на него спекл-шума и выдаст его на выходе. Таким образом, обучив НС на подготовленном наборе данных, получим фильтр мультипликативного спекл-шума.

2.2 Оценка качества фильтрации мультипликативного шума

В процессе разработки алгоритма фильтрации важную роль играет задача оценки качества принятых изображений.

На сегодняшний день существует множество оценок качества изображений, которые можно разделить на две основные группы: субъективные оценки и математические оценки (метрики). Несмотря на то, что

субъективный метод, предполагаемый участие группы экспертов, является надёжным способом определения качества изображений, на его реализацию необходимо много времени и средств. Поэтому для ускорения процесса оценки качества изображений используются математические методы.

В большинстве случаев метрики дают результат, не сильно приближённый к человеческому восприятию. Следовательно, при работе с изображениями важно выбрать ту метрику, которая даст наиболее адекватную, с точки зрения человека, оценку качества. Рассмотрим наиболее распространенные математические оценки качества изображений [12]:

1) Средний квадрат отклонения (*MSE – mean squared error*)

MSE является самой распространённой метрикой оценивания качества изображений, которая определяет среднеквадратичное отклонение оцениваемого изображения от эталонного и вычисляется по формуле:

$$MSE = \frac{1}{nm} \sum_{i=1}^n \sum_{j=1}^m |\hat{I}_{ij} - I_{ij}|^2, \quad (2.1)$$

где $n \times m$ – размер изображения,

I – значение яркости пикселя незашумленного изображения,

\hat{I} – значение яркости пикселя изображения после фильтрации.

Чем значение *MSE* ближе к нулю, тем более схожи оцениваемое и эталонное изображения. Данная метрика привлекательна тем, что она легко реализуется, однако зачастую плохо коррелирует с субъективными оценками.

2) Средний модуль отклонения (*MAE – mean absolute error*)

MAE рассчитывается как среднее абсолютных разностей между оцениваемым изображением и эталонным:

$$MAE = (1/nm) \sum_{i=1}^n \sum_{j=1}^m |\hat{I}_{ij} - I_{ij}|, \quad (2.2)$$

Данная метрика является линейной, поэтому она меньше подвержена влиянию выбросов, чем *MSE*.

3) Пиковое отношение сигнал/шум (*PSNR – peak signal-to-noise ratio*)

Данная метрика показывает соотношение между максимально возможным значением сигнала и мощностью шума, который искажает этот сигнал, и вычисляется по следующей формуле:

$$PSNR = 20 \log_{10}(M/\sqrt{MSE}). \quad (2.3)$$

где M – максимально возможное значение интенсивности, принимаемым пикселем изображения, и равно 255.

Хотя метрика *PSNR* аналогична среднеквадратичному отклонению и ей присущи те же особенности, что и *MSE*, пользоваться ею удобнее из-за логарифмического масштаба.

4) Индекс структурного сходства (*SSIM – structure similarity index*)

Данная метрика позволяет оценить степень сходства соответствующих участков («скользящих» окнах) сравниваемых изображений по трем относительно независимым составляющим: яркость, контраст и структура. На каждом шаге для «скользящего» окна метрика вычисляется по формуле:

$$SSIM(I, \hat{I}) = ((2\mu_I\mu_{\hat{I}} + C_1)(2\sigma_{I\hat{I}} + C_2)) / ((\mu_I^2 + \mu_{\hat{I}}^2 + C_1)(\sigma_I^2 + \sigma_{\hat{I}}^2 + C_2)), \quad (2.4)$$

где μ_I и $\mu_{\hat{I}}$ – средние значения незашумленного изображения и изображения после фильтрации соответственно,

σ_I^2 и $\sigma_{\hat{I}}^2$ – дисперсии незашумленного изображения и изображения после фильтрации соответственно,

$\sigma_{I\hat{I}}$ – ковариация незашумленного изображения и изображения после фильтрации,

$C_1 = (k_1L)^2$, $C_2 = (k_2L)^2$ – переменные, где $L = 2^{\text{бит на пиксел}} - 1$, $k_1 = 0,01$, $k_2 = 0,03$.

Итоговое значение *SSIM* определяется как среднее по всем вычисленным в окнах значениям:

$$SSIM(I, \hat{I}) = \frac{1}{m} \sum_{i=1}^m SSIM(I, \hat{I})_i, \quad (2.5)$$

где m – количество окон.

Чем ближе значение $SSIM$ к 1, тем оцениваемое изображение ближе к эталонному.

На сегодняшний день метрика $SSIM$ является наиболее предпочтительной при оценке качества изображений. В отличие от предыдущих метрик она обладает хорошей согласованностью со значениями экспертных оценок, так как зрительная система человека хорошо воспринимает структурные элементы [13, 14, 15]. Исходя из этого, выберем метрику $SSIM$ для оценки качества изображений после фильтрации мультипликативного шума нейросетевым подходом.

2.3 Выводы

В данном разделе было представлено описание архитектуры НС для фильтрации мультипликативного шума на РЛИ. Также были рассмотрены стандартные метрики качества изображений после фильтрации шума. Для дальнейшей оценки качества РЛИ после обработки мультипликативного шума нейросетевым подходом будем использовать индекс структурного сходства $SSIM$.

3 Фильтрация мультипликативного шума на РЛИ

Внимание проведённой работы было сконцентрировано на реализации и применении метода фильтрации мультипликативного шума на радиолокационных изображениях нейросетевым подходом.

3.1 Разработка фильтра мультипликативного шума

Для обучения ИНС и оценивания работы фильтра необходимо наличие незашумлённого эталонного изображения, на которое накладывается шум. Так как идеального РЛИ без шума не существует, необходимо создать смоделированные РЛИ путём наложения спекл-шума на оптические изображения. Для этого необходимо знать, каким распределением описывается спекл-шум и какие у него статистические параметры.

Для этого в работе [16], выделив на некотором количестве реальных РЛИ однородные фрагменты, не содержащие каких-либо объектов, построили для них гистограммы и провели оценку статистических параметров в предположении о различных распределениях спекл-шума. В результате было обнаружено, что спекл-шум имеет одинаковое распределение во всех фрагментах, а его плотность вероятности можно аппроксимировать распределением Рэлея, масштабный параметр σ которого был оценен как 0,2707.

Зная распределение спекл-шума, можно приступить к обучению НС, описанной в разделе 2, для фильтрации мультипликативного спекл-шума. Для её обучения было использовано 10 оптических изображений, которые перевели в цветовую модель grayscale. На эталонные изображения наложили мультипликативный спекл-шум с распределением Рэлея с параметром масштаба 0,2707. Примеры изображений для обучения нейронной сети для фильтрации мультипликативного спекл-шума представлены на Рисунке 3.1.




Рисунок 3.1 – а,б,в) Эталонные изображения; г,д,е) Изображения с наложенным на них спекл-шумом с распределением Рэлея (масштабный параметр $\sigma = 0,2707$)

Поскольку задачей данной работы является повышения качества РЛИ методом фильтрации мультипликативного спекл-шума, то необходимо провести выбор оптимального размера скользящего окна фильтра $m \times m$. Для выбора оптимального параметра будем использовать изображение, содержащее мелкие объекты (круги, звезда и треугольник), большой объект в виде круга и разделяющую границу между двумя областями разной яркости. Тестовое изображение представлено на Рисунке 3.2.




Рисунок 3.2 – Тестовое изображение размера 500×500 для исследования работы разработанного фильтра

Применяя фильтрацию тестового изображения после наложения шума с распределением Рэля, рассмотрим зависимость значений метрики *SSIM* от различных значений размера стороны окна (Рисунок 3.3).

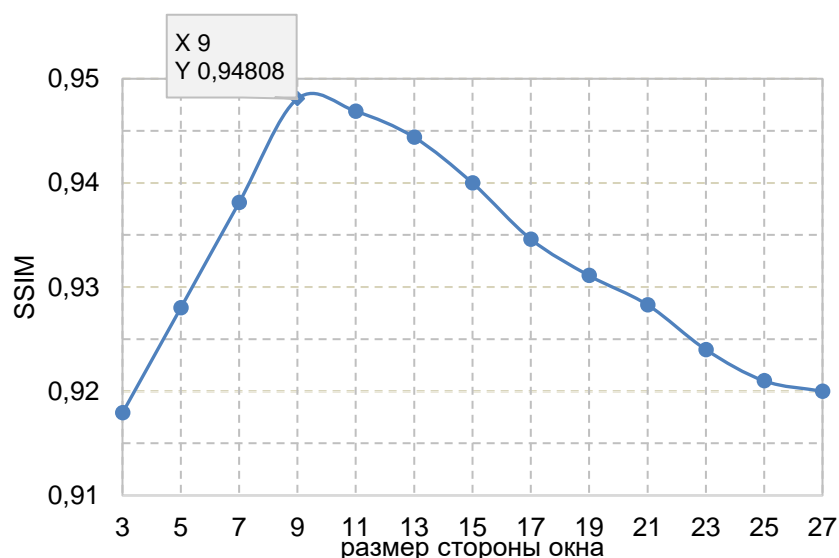




Рисунок 3.3 – Зависимость значений метрики *SSIM* от различных размеров скользящего окна фильтра

В соответствии с Рисунком 3.3 получаем, что при максимуме метрики $SSIM = 0,94808$ оптимальный размер окна фильтра равен 9×9 .

Тестовое изображение с наложенным на него спекл-шумом с распределением Рэля с параметром масштаба 0,2707 и после обработки фильтром размера 9×9 на основе НС представлены на Рисунке 3.4.



а)




б)

Рисунок 3.4 – а) Тестовое изображение с наложенным на него спекл-шумом с распределением Рэля (масштабный параметр $\sigma = 0,2707$); б) Тестовое изображение после обработки спекл-шума с распределением Рэля (масштабный параметр $\sigma = 0,2707$) фильтром оптимального размера 9×9

Также рассмотрим работу разработанного фильтра оптимального размера 9×9 на локальных областях тестового изображения, чтобы понять, с какими типами объектов данный фильтр справляется лучше. Для этого рассмотрим значения метрики *SSIM* в следующих областях: с мелкими объектами, с большим объектом и с границей. Выбранные для исследования области представлены на Рисунке 3.5. Значения метрики *SSIM* до и после фильтрации локальных объектов представлены в таблице 3.1.



а)



б)



в)

Рисунок 3.5 – а) Область с границей без наложения спекл-шума; б) Область с большим объектом без наложения спекл-шума; в) Область с мелкими объектами без наложения спекл-шума

Таблица 3.1 – Значение метрики *SSIM* до и после фильтрации локальных объектов

Область	<i>SSIM</i> до фильтрации	<i>SSIM</i> после фильтрации
С мелкими объектами	0,57124	0,91932
С большим объектом	0,32603	0,91498
С границей	0,51721	0,94396

Из полученных результатов метрики *SSIM* видно, что фильтр, разработанный на основе НС, лучше справляется с областью, содержащей границу. Локальные области тестового изображения после фильтрации спекл-шума представлены на Рисунке 3.6.




Рисунок 3.6. – Область с границей (а), область с большим объектом (б) и область с мелкими объектами (в) после обработки спекл-шума с распределением Рэлея (масштабный параметр $\sigma = 0,2707$) фильтром оптимального размера 9×9

3.2 Применение фильтра мультипликативного шума на реальных изображениях

Теперь протестируем работу фильтра, разработанного на основе НС, на реальных оптических изображениях и сравним значения метрики *SSIM* при выбранном оптимальном параметре и при нескольких неоптимальных параметрах. Для тестирования выберем 100 изображений, содержащие наиболее часто встречающиеся объекты, такие как машины, самолёты, корабли, здания, дороги, и равномерные участки. Пример выбранных изображений для тестирования фильтра представлены на Рисунке 3.7.




Рисунок 3.7 – а) Тестовое изображение №1; б) Тестовое изображение №2; в) Тестовое изображение №3; г) Тестовое изображение №4; д) Тестовое изображение №5; е) Тестовое изображение №6

Наложим на тестовые изображение спекл-шум с распределением Рэлея, произведем обработку фильтром с оптимальным размером окна 9×9 , и фильтрами с неоптимальными размерами 7×7 и 11×11 . В таблицах 3.2-3.3 представлены средние значения метрики *SSIM* при обработке тестовых реальных изображений нейросетевым подходом при оптимальном и неоптимальных параметрах, а также в таблице 3.2 приведено среднее время обработки одного из таких изображений на процессоре Intel Core i5 (2.4 ГГц).

В таблице 3.3 символом Δ обозначена разница в процентах между значениями метрики *SSIM* при оптимальном и неоптимальном параметрах фильтра. Неоптимальные параметры, выбранные для сравнения, указаны в нижнем индексе символа Δ .

Таблица 3.2 – Среднее значение метрики *SSIM* при обработке тестовых изображений нейросетевым подходом при оптимальном и неоптимальных параметрах

Фильтр	Параметр фильтра	<i>SSIM</i>	Среднее время, с
Без фильтра	-	0,5189	-
Нейросетевой подход	7×7	0,8713	7,7190
	9×9	0,8822	9,0982
	11×11	0,8812	9,1780

Таблица 3.3 – Значение метрики *SSIM* при обработке тестовых изображений нейросетевым подходом при оптимальном и неоптимальных параметрах

Номер изображения	<i>SSIM</i> при оптимальном парамetre 9×9	<i>SSIM</i> при 7×7	$\Delta_{7 \times 7}$, %	<i>SSIM</i> при 11×11	$\Delta_{11 \times 11}$, %
1	0,91528	0,90964	0,62	0,91464	0,07
2	0,86074	0,85074	1,16	0,86037	0,04
3	0,91123	0,89900	1,34	0,90879	0,27
4	0,88895	0,87779	1,25	0,88711	0,21
5	0,92566	0,90442	2,30	0,90976	1,72
6	0,95433	0,93907	1,60	0,94086	1,41

Как видно из таблиц 3.2-3.3, разница между значениями метрики *SSIM* при оптимальном и неоптимальных параметрах фильтра в некоторых случаях достигает несколько процентов, что свидетельствует о важности выбора размера окна обработки мультипликативного шума нейросетевым подходом для повышения качества изображений. Также по результатам таблицы 3.2, можно сделать вывод, что при увеличении размера окна фильтра время обработки одного реального изображения тоже увеличивается.

Также на реальных тестовых изображениях сравним работу фильтра, разработанного на основе НС, с классическими методами фильтрации, описанными в разделе 1, используя оптимальные параметры из исследований [17]. В таблице 3.4 представлены средние значения метрики для всех фильтров при обработке выбранных реальных изображений и среднее время обработки одного из таких изображений на процессоре Intel Core i5 (2.4 ГГц).

Таблица 3.4 – Среднее значение метрики *SSIM* для всех фильтров при обработке реальных изображений

Фильтр	Параметр фильтра	Оптимальное значение фильтра	<i>SSIM</i>	Среднее время, с
Без фильтра	-	-	0,5189	-
Нейросетевой подход	Размер окна	9×9	0,8822	9,0982
Медианный	Размер окна	15×15	0,7058	1,7625
Ли	Размер окна	9×9	0,7545	1,7070
Фроста	Размер окна	13×13	0,8160	2,7913
	D	14		
Куана	Размер окна	15×15	0,5253	2,1752
	A	-0,1		
Билатериальный	Размер окна	15×15	0,8264	2,9823
	σ_d^2	5		
	σ_r^2	1		
МАР фильтр	Размер окна	11×11	0,7636	2,1259
Анизотропная диффузия при экспоненциальн ой $g(x)$	Δt	0,23	0,7860	0,3498
	k	0,2		
	t	12		
Анизотропная диффузия при квадратичной $g(x)$	Δt	0,24	0,7974	0,3297
	k	0,1		
	t	12		

Как видно из таблицы 3.4, применение фильтра, разработанного на основе НС, даёт лучшие результаты по метрике *SSIM* при обработке спекл-шума с распределением Рэля. Также среди рассматриваемых фильтров, с фильтрацией спекл-шума лучше по метрике *SSIM* справляются фильтр Фроста и Билатериальный фильтр.

Согласно таблице 3.4 на обработку реальных изображений нейросетевым подходом необходимо больше времени, чем другими фильтрами. Лучшие результаты по времени обработки изображений показал фильтр анизотропной диффузии с квадратичной и экспоненциальной функцией $g(x)$.

Реальные тестовые изображения с наложенным на них спекл-шумом с распределением Рэля представлены на Рисунке 3.8. На Рисунке 3.8 и далее представлены наиболее характерные фрагменты реальных изображений для улучшения визуализации.




Рисунок 3.8 – Реальные изображения №1 (а), №2 (б), №3 (в), №4 (г), №5 (д) и №6 (е) с наложенным на них спекл-шумом с распределением Рэля (масштаб $\sigma = 0,2707$)

Реальные тестовые изображения после обработки тремя лучшими по метрике *SSIM* фильтрами спекл-шума с распределением Рэлея представлены на Рисунках 3.9-3.11.





Рисунок 3.9 – Реальные изображения №1 (а), №2 (б), №3 (в), №4 (г), №5 (д) и №6 (е) после обработки спекл-шума с распределением Рэлея (масштабный параметр $\sigma = 0,2707$) фильтром, разработанным нейросетевым подходом






Рисунок 3.10 – Реальные изображения №1 (а), №2 (б), №3 (в), №4 (г), №5 (д) и №6 (е) после обработки спекл-шума с распределением Рэлея (масштабный параметр $\sigma = 0,2707$) фильтром Фроста





Рисунок 3.11 – Реальные изображения №1 (а), №2 (б), №3 (в), №4 (г), №5 (д) и №6 (е) после обработки спекл-шума с распределением Рэлея (масштабный параметр $\sigma = 0,2707$) Билатериальным фильтром

Также для визуализации работы фильтров можно использовать одномерные срезы изображений, чтобы оценить насколько срез изображения после фильтрации совпадает со срезом до наложения шума. Пример одномерных срезов для всех фильтров представлен на Рисунке 3.12. В данном случае взяли немного измененное реальное изображение, чтобы срез прошёл через важные объекты. Графики на Рисунке 3.12 б) разнесены для удобства визуализации, чтобы они не накладывались друг на друга. Введённый между кривыми интервал равен 0,2.



а)



б)

Рисунок 3.12 – а) Реальное изображение без наложения шума с указанием линии среза; б) Значения интенсивности пикселей вдоль среза для реального изображения до и после фильтрации спекл-шума с распределением Рэлея (масштабный параметр $\sigma = 0,2707$) различными методами

Как видно из Рисунка 3.12 б), срез изображения после фильтрации нейросетевым подходом практически совпадает со срезом до наложения спекл-шума с распределением Рэлея, что подтверждает результаты, полученные в таблице 3.4. Также наиболее гладкими срезами обладают медианный фильтр, фильтр Фроста, фильтр анизотропной диффузии при квадратичной и экспоненциальной функции $g(x)$.

3.3 Выводы

В данной главе была представлена реализация метода повышения качества радиолокационных изображений. С помощью НС был разработан фильтр мультипликативного спекл-шума, который лежит в основе данного метода. Для оценивания качества изображений после фильтрации спекл-шума с распределением Рэлея служил индекс структурного сходства *SSIM*. Был проведён поиск оптимального параметра фильтра. Сравнение значений метрики *SSIM* при оптимальном и неоптимальных параметрах показало, что при оптимальном параметре выигрыш достигает несколько процентов.

Сравнивая работу разработанного фильтра на основе НС с классическими методами фильтрации, можно сделать вывод, что при фильтрации реальных изображений с наложенным спекл-шумом с распределением Рэлея по метрике *SSIM* лучше справляется нейросетевой подход. Также при обработке изображений близкие результаты показали фильтр Фроста и билатеральный фильтр. Однако фильтр Фроста, хорошо сглаживая шум на однородных областях и больших объектов, оставляет зернистость по краям объектов, а билатеральный фильтр – на однородных областях. Таким образом, при дальнейшей обработке РЛИ рекомендуется использовать нейросетевой подход фильтрации спекл-шума.

Несмотря на то, что выполнение обработки реальных изображений нейросетевым подходом занимает больше времени, чем другими фильтрами, для повышения качества РЛИ рекомендуется применять фильтр мультипликативного спекл-шума на основе НС, который способен

эффективно сглаживать шум на однородных областях и сохранять границы объектов.

ЗАКЛЮЧЕНИЕ

В ходе работы был реализован алгоритм фильтрации мультипликативного спекл-шума на РЛИ на основе искусственных нейронных сетей. При использовании нейронной сети, обучение которой производилось на разработанном наборе данных, получили фильтр мультипликативного спекл-шума, способный адаптироваться под каждый пиксель изображения и его окружения внутри «скользящего» окна.

Для повышения качества РЛИ методом фильтрации мультипликативного спекл-шума провели поиск оптимального размера окна фильтра по метрике *SSIM*. В итоге при обработке тестового изображения, содержащего мелкие объекты, большой объект и границу, при рэлеевском распределении спекл-шума определили, что оптимальный размер окна фильтра равен 9×9 .

Рассматривая работу фильтра оптимального размера 9×9 на локальных областях тестового изображения, было получено, что по метрике *SSIM* такой фильтр лучше справляется с областью, содержащей границу.

Фильтрация нейросетевым подходом была применена к реальным оптическим изображениям. Разница между значениями метрики *SSIM* при оптимальном и неоптимальном параметрах фильтра в некоторых случаях достигала нескольких процентов. Также с увеличением размера окна фильтра, основанного на НС, получили, что время обработки одного изображения увеличивается. Таким образом, такие результаты говорят о важности выбора оптимального параметра фильтра мультипликативного спекл-шума для обработки изображений.

Сравнение работы разработанного фильтра на основе НС с классическими методами фильтрации показало, что при фильтрации реальных изображений с наложенным спекл-шумом с распределением Рэлея по метрике *SSIM* лучше справился нейросетевой подход. Также при обработке изображений близкие результаты показали фильтр Фроста и билатеральный

фильтр. Однако фильтр Фроста, хорошо сглаживая шум на однородных областях и больших объектах, оставляет зернистость по краям объектов, а билатеральный фильтр – на однородных областях.

Выполнение обработки реальных изображений нейросетевым подходом занимает больше времени, чем другими фильтрами. Хотя лучшие результаты по времени обработки изображений показал фильтр анизотропной диффузии с квадратичной и экспоненциальной функцией $g(x)$, такой фильтр сильно разглаживает границы объектов. Следовательно, для повышения качества РЛИ рекомендуется применять фильтр мультипликативного спекл-шума на основе НС, который способен эффективно сглаживать шум на однородных областях и сохранять границы объектов.

Поставленные задачи были выполнены. В качестве дальнейшей работы по развитию алгоритма фильтрации мультипликативного спекл-шума на РЛИ предлагается обучать НС на новом наборе данных с целью повышения качества РЛИ.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Бакулев П. А. Радиолокационные системы. Учебник для вузов. – М.: Радиотехника, 2004. – 320 с.
2. Верба В.С., Неронский Л.Б., Осипов И.Г. и др. Радиолокационные системы землеобзора космического базирования. / Под редакцией доктора технических наук, профессора В.С. Вербы. – М.: Радиотехника, 2010. – 680 с.
3. Кондратенков Г.С., Фролов А.Ю. Радиовидение. Радиолокационные системы дистанционного зондирования Земли. Учебное пособие для вузов. / Под редакцией Г. С. Кондратенкова. – М.: Радиотехника, 2005. – 368 с.
4. R. C. Gonzalez, R. E. Woods. Digital Image Processing. Second edition – USA, New Jersey: Wesley Longman Publishing Co., Inc. 2001. – 191 p.
5. Jong-Sen Lee, "Digital Image Enhancement and Noise Filtering by Use of Local Statistics," in *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. PAMI-2, no. 2, pp. 165-168, March 1980, doi.: 10.1109/TPAMI.1980.4766994.
6. V. S. Frost, J. A. Stiles, K. S. Shanmugan, J. C. Holtzman, "A Model for Radar Images and Its Application to Adaptive Digital Filtering of Multiplicative Noise," in *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. PAMI-4, no. 2, pp. 157-166, March 1982, doi: 10.1109/TPAMI.1982.4767223.
7. D. Kuan, A. Sawchuk, T. Strand, P. Chavel, "Adaptive restoration of images with speckle," in *IEEE Transactions on Acoustics, Speech and Signal Processing*, vol. 35, no. 3, pp. 373–383, March 1987, doi: 10.1109/TASSP.1987.1165131.
8. C. Tomasi, R Manduchi, "Bilateral filtering for gray and color images," *6th International Conference on Computer Vision (ICCV)*, 1998, pp. 839–846, doi.: 10.1109/ICCV.1998.710815.
9. A. Lopes, E. Nezry, R. Touzi, H. Laur, "Structure detection and statistical adaptive speckle filtering in SAR images," *International Journal of Remote Sensing*, vol. 14, no. 9, pp. 1735-1758, 1993, doi: 10.1080/01431169308953999.

10. P. Perona, J. Malik, "Scale-space and edge detection using anisotropic diffusion," in *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 12, no. 7, pp. 629-639, July 1990, doi.:10.1109/34.56205.
11. Николенко С., Кадури́н А., Архангельская Е., Глубокое обучение. – СПб.: Питер, 2018. – 480 с.
12. Стрижов В.В. Функция ошибки в задачах восстановления регрессии // Заводская лаборатория. – 2013. – № 79(5). – С. 65-73.
13. Сидоров Д.В. К вопросу оценки качества множества восстановленных изображений // Прикладная информатика. – 2008. – № 4(16). – С. 92-95.
14. Swati A. Gandhi, C.V. Kulkarni, "MSE Vs SSIM," in *International Journal of Scientific & Engineering Research*, vol. 4, no 7, pp. 930-934, July 2013.
15. Zhou Wang, Alan C. Bovik, Hamid R. Sheikh et al, "Image Quality Assessment: From Error Visibility to Structural Similarity," in *IEEE transactions on image processing*, vol. 13, no. 4, pp. 1-14, April 2004, doi.: 10.1109/TIP.2003.819861.
16. V. A. Pavlov, A. A. Belov, A. A. Tuzova, "Investigation of the Influence of Speckle Noise on the Accuracy of the Object Detection by Convolutional Neural Network," *2021 International Conference on Electrical Engineering and Photonics (EExPolytech)*, 2021, pp. 47-50, doi.: 10.1109/EExPolytech53083.2021.9614850.
17. Тузова А.А., Павлов В.А., Белов А.А. Подавление мультипликативного шума на радиолокационных изображениях // Изв. вузов России. – Радиоэлектроника. – 2021. – Т.24, №4. – С. 6-8.